

# Inteligência Artificial


## Lista 5

### Vitor Dias de Britto Militão

#### Questão 1:

- Número de *Itemsets* de tamanho 1 que atendem ao suporte mínimo de 0,3: **7**
- Número de *Itemsets* de tamanho 2 que atendem ao suporte mínimo de 0,3: **6**
- Número de *Itemsets* de tamanho 3 que atendem ao suporte mínimo de 0,3: **0**
- Número de regras que atendem à confiança mínima de 0,8: **1**

#### Questão 2:



	Antecedente	Consequente	suporte	confianca	lift
0	[Nao]	[Sim]	0.909091	1.0	1.1
1	[Sim]	[Nao]	0.909091	1.0	1.1

#### Questão 5:

A biblioteca mixtend é uma ferramenta prática para gerar regras de associação a partir de dados transacionais, especialmente em análises de cestas de compras. Utilizando o algoritmo Apriori, a mixtend permite identificar padrões frequentes e relacionamentos entre itens, com base em valores mínimos de suporte e confiança.

### Principais Etapas para Geração de Regras de Associação

- Preparação dos Dados:**
  - Os dados transacionais devem estar em formato binário (1 para item presente, 0 para item ausente). Cada linha representa uma transação e cada coluna representa um item.
- Extração de Conjuntos de Itens Frequentes:**
  - A função `apriori` da `mlxtend.frequent_patterns` é usada para identificar conjuntos de itens que atendem a um suporte mínimo especificado.
  - Parâmetros importantes:
    - `min_support`: Define o suporte mínimo para que um itemset seja considerado frequente.
    - `use_colnames=True`: Exibe os nomes dos itens nos resultados.
- Geração de Regras de Associação:**
  - A função `association_rules` gera regras a partir dos conjuntos de itens frequentes, com base em uma métrica como confiança ou lift.
  - Parâmetros importantes:

- `metric`: Define a métrica para avaliar as regras, como "confidence" ou "lift".
- `min_threshold`: Define o valor mínimo para a métrica escolhida.

## Benefícios

Essa abordagem é valiosa em diversas áreas de análise de dados, especialmente para entender padrões de compra, identificar produtos frequentemente adquiridos juntos e apoiar decisões de marketing e estratégias de vendas.

## Questão 6:

Este artigo revisa o estado da arte na mineração de regras de associação (Association Rule Mining - ARM), com ênfase nas técnicas de visualização dos resultados, um passo essencial para a compreensão e análise das regras geradas. A mineração de regras de associação é uma técnica popular em mineração de dados e aprendizado de máquina, usada para descobrir relacionamentos entre itens em grandes bases de dados transacionais. A técnica foi originalmente desenvolvida com o algoritmo Apriori, proposto por Agrawal em 1994, e evoluiu ao longo do tempo para incluir algoritmos mais eficientes, como Eclat, FP-growth, e métodos baseados em heurísticas e estocásticos.

O processo de ARM envolve três etapas principais: pré-processamento (limpeza e preparação dos dados), mineração de regras (descoberta dos padrões de associação) e pós-processamento (visualização e interpretação dos resultados). A visualização é uma parte crítica desse processo, pois facilita o entendimento e a análise dos dados por usuários não técnicos. Além disso, a tendência recente na área de Inteligência Artificial Explicável (XAI) tem incentivado o desenvolvimento de métodos de visualização que tornam os modelos de aprendizado de máquina mais transparentes e interpretáveis, ajudando a construir confiança nos resultados.

Este artigo oferece uma revisão das técnicas de visualização de ARM publicadas em periódicos revisados por pares, abordando os principais métodos e suas características, além de explorar aplicações práticas em áreas como análise de mercado, diagnóstico médico e análise de dados censitários. O estudo também propõe um resumo das vantagens e desvantagens de cada método, bem como exemplos de uso, e sugere futuras direções para a pesquisa em visualização de regras de associação no contexto de XAI.